

第 11 回 操作変数法 (8)

村澤 康友

2022 年 12 月 22 日

今日のポイント

1. 説明変数と誤差項が無相関であることが OLS 推定量の一致性の必要十分条件. 説明変数の欠落や内生性は OLS 推定量に偏りをもたらす.
2. 説明変数と相関があり, 誤差項と無相関の変数を操作変数 (IV) という. 線形モデルの一致推定には係数の数だけ IV が必要. IV を用いる推定手法を操作変数 (IV) 法という.
3. 各説明変数を全ての IV に回帰して回帰予測を求め, それに被説明変数を回帰する手法を 2 段階最小 2 乗法 (2SLS) という. IV 法は 2SLS で実行する.

目次

1	OLS 推定量の偏り	1
1.1	OLS 推定量の一致性 (p. 191)	1
1.2	欠落変数バイアス (p. 139)	2
1.3	内生性バイアス (p. 191)	2
2	操作変数 (IV) 法	2
2.1	操作変数 (IV) (p. 192)	2
2.2	識別 (p. 195)	3
2.3	IV 推定量 (p. 194)	3
2.4	弱い IV (p. 202)	4
3	2 段階最小 2 乗法 (2SLS)	4
3.1	2 段階最小 2 乗法 (2SLS) (p. 205)	4
3.2	構造形と誘導形 (pp. 196, 206)	4

4	今日のキーワード	4
5	次回までの準備	4

1 OLS 推定量の偏り

1.1 OLS 推定量の一致性 (p. 191)

$((y_1, x_1), \dots, (y_n, x_n))$ を無作為標本とする. 簡単化のため定数項のないモデルで考える. y_i の x_i 上への定数項のない線形モデルは

$$y_i = \beta x_i + u_i \\ E(u_i) = 0$$

β の OLS 推定量を b_n とすると

$$b_n = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

$E(x_i^2) > 0$ (x_i は 0 以外の値を取り得る) とする.

定理 1.

$$E(x_i u_i) = 0 \iff \text{plim}_{n \rightarrow \infty} b_n = \beta$$

証明. b_n の式に $y_i = \beta x_i + u_i$ を代入すると

$$b_n = \frac{\sum_{i=1}^n x_i (\beta x_i + u_i)}{\sum_{i=1}^n x_i^2} \\ = \beta + \frac{\sum_{i=1}^n x_i u_i}{\sum_{i=1}^n x_i^2} \\ = \beta + \frac{(1/n) \sum_{i=1}^n x_i u_i}{(1/n) \sum_{i=1}^n x_i^2}$$

大数の法則より

$$\text{plim}_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i^2 = E(x_i^2) \\ \text{plim}_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i u_i = E(x_i u_i)$$

スルツキーの定理より

$$\text{plim}_{n \rightarrow \infty} b_n = \beta + \frac{E(x_i u_i)}{E(x_i^2)}$$

したがって一致性の必要十分条件は $E(x_i u_i) = 0$.

□

注 1. $E(u_i) = 0$ なので $E(x_i u_i) = \text{cov}(x_i, u_i)$.

注 2. 回帰モデルなら繰り返し期待値の法則より $E(u_i | x_i) = 0 \implies E(x_i u_i) = 0$. すなわち一致性の必要十分条件を満たす.

1.2 欠落変数バイアス (p. 139)

(Y, X, Z) を確率ベクトルとする. Y の (X, Z) 上への重回帰モデルは

$$Y = \alpha + \beta X + \gamma Z + U \\ E(U | X, Z) = 0$$

説明変数から Z が欠落すると

$$Y = \alpha + \beta X + V$$

ただし $V := \gamma Z + U$.

定理 2.

$$E(XV) = \gamma E(XZ)$$

証明.

$$E(XV) = E(X(\gamma Z + U)) \\ = \gamma E(XZ) + E(XU)$$

繰り返し期待値の法則より第 2 項は

$$E(XU) = E(E(XU | X, Z)) \\ = E(X E(U | X, Z)) \\ = 0$$

□

注 3. したがって $\gamma = 0$ または $E(XZ) = 0$ でない限り OLS 推定量は偏りをもつ.

定義 1. 説明変数の欠落によって生じる OLS 推定量の偏りを **欠落変数バイアス** という.

1.3 内生性バイアス (p. 191)

確率ベクトル (Y_1, Y_2, X) は次の連立方程式を満たす.

$$Y_1 = -\gamma_{1,2} Y_2 + \beta X + U_1 \\ Y_2 = -\gamma_{2,1} Y_1 + \beta X + U_2$$

$$E \left(\begin{pmatrix} U_1 \\ U_2 \end{pmatrix} | X \right) = \mathbf{0} \\ \text{var} \left(\begin{pmatrix} U_1 \\ U_2 \end{pmatrix} | X \right) = \begin{bmatrix} \sigma_{1,1} & \sigma_{1,2} \\ \sigma_{2,1} & \sigma_{2,2} \end{bmatrix}$$

第 1 式の OLS 推定を考える.

定理 3.

$$E(Y_2 U_1) = \frac{-\gamma_{2,1} \sigma_{1,1} + \sigma_{1,2}}{1 - \gamma_{2,1} \gamma_{1,2}}$$

証明. 繰り返し期待値の法則より $E(U_1 | X) = 0 \implies E(X U_1) = 0$ なので

$$E(Y_2 U_1) = E((- \gamma_{2,1} Y_1 + \beta X + U_2) U_1) \\ = -\gamma_{2,1} E(Y_1 U_1) + \sigma_{1,2} \\ = -\gamma_{2,1} E((- \gamma_{1,2} Y_2 + \beta X + U_1) U_1) + \sigma_{1,2} \\ = \gamma_{2,1} \gamma_{1,2} E(Y_2 U_1) - \gamma_{2,1} \sigma_{1,1} + \sigma_{1,2}$$

これを $E(Y_2 U_1)$ について解けばよい. □

注 4. したがって $\gamma_{2,1} = 0$ かつ $\sigma_{1,2} = 0$ でない限り OLS 推定量は偏りをもつ.

定義 2. システム (連立方程式) の外部で決定される変数を **外生変数** という.

定義 3. 外生変数を所与としてシステムの内部で決定される変数を **内生変数** という.

定義 4. 説明変数に内生変数があることで生じる OLS 推定量の偏りを **内生性バイアス** という.

2 操作変数 (IV) 法

2.1 操作変数 (IV) (p. 192)

(Y, X, Z) を確率ベクトルとする. 簡単化のため定数項のないモデルで考える. Y の X 上への定数項のない線形モデルは

$$Y = \beta X + U \\ E(U) = 0$$

定義 5. 線形モデルの説明変数と相関があり、誤差項と相関がない変数を**操作変数** (*Instrumental Variable, IV*) という。

注 5. $E(ZX) \neq 0$ で $E(ZU) = 0$ なら Z は β の推定の IV.

注 6. 回帰モデルなら繰り返し期待値の法則より $E(U|X) = 0 \implies E(XU) = 0$. また X が 0 以外の値を取り得るなら $E(X^2) = E(X^2) \neq 0$. したがって X が IV となる。

定義 6. 操作変数を用いる推定手法を**操作変数 (IV) 法**という。

定理 4.

$$\beta = \frac{E(ZY)}{E(ZX)}$$

証明. $U := Y - \beta X$ より

$$\begin{aligned} E(ZU) &= E(Z(Y - \beta X)) \\ &= E(ZY) - \beta E(ZX) \end{aligned}$$

左辺 = 0 より結果が得られる。□

注 7. この式に MM 法を適用して β を推定する。

2.2 識別 (p. 195)

定義 7. 母数の一致推定量が存在するなら母数は**識別可能**という。

注 8. 線形モデルの係数の識別には推定する係数の数だけ IV が必要。

2.3 IV 推定量 (p. 194)

$((y_1, x_1, z_1), \dots, (y_n, x_n, z_n))$ を無作為標本とする。簡単化のため定数項のないモデルで考える。 y_i の x_i 上への定数項のない線形モデルは

$$\begin{aligned} y_i &= \beta x_i + u_i \\ E(u_i) &= 0 \end{aligned}$$

定義 8. β の IV 推定量は

$$b_n := \frac{\sum_{i=1}^n z_i y_i}{\sum_{i=1}^n z_i x_i}$$

注 9. IV を用いた MM 法と解釈できる。

注 10. $z_i = x_i$ なら IV 推定量 = OLS 推定量。

定理 5.

$$\text{plim}_{n \rightarrow \infty} b_n = \beta$$

証明. 復習テスト。□

定理 6.

$$\sqrt{n}(b_n - \beta) \xrightarrow{d} N\left(0, \frac{\text{var}(z_i u_i)}{E(z_i x_i)^2}\right)$$

証明. b_n の式に $y_i = \beta x_i + u_i$ を代入すると

$$\begin{aligned} b_n &= \frac{\sum_{i=1}^n z_i (\beta x_i + u_i)}{\sum_{i=1}^n z_i x_i} \\ &= \beta + \frac{\sum_{i=1}^n z_i u_i}{\sum_{i=1}^n z_i x_i} \end{aligned}$$

式変形すると

$$\sqrt{n}(b_n - \beta) = \frac{(1/\sqrt{n}) \sum_{i=1}^n z_i u_i}{(1/n) \sum_{i=1}^n z_i x_i}$$

大数の法則より

$$\text{plim}_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n z_i x_i = E(z_i x_i)$$

$E(z_i u_i) = 0$ なので中心極限定理より

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n z_i u_i \xrightarrow{d} N(0, \text{var}(z_i u_i))$$

スルツキーの定理とクラメルの定理より

$$\frac{(1/\sqrt{n}) \sum_{i=1}^n z_i u_i}{(1/n) \sum_{i=1}^n z_i x_i} \xrightarrow{d} N\left(0, \frac{\text{var}(z_i u_i)}{E(z_i x_i)^2}\right)$$

□

注 11. $\text{var}(z_i u_i)$ は White の推定量で推定する。

系 1. $\text{var}(u_i | z_i) = \sigma^2$ なら

$$\sqrt{n}(b_n - \beta) \xrightarrow{d} N\left(0, \frac{\sigma^2}{E(z_i x_i)^2 / E(z_i^2)}\right)$$

証明. $E(z_i u_i) = 0$ より

$$\begin{aligned} \text{var}(z_i u_i) &= E((z_i u_i)^2) \\ &= E(z_i^2 u_i^2) \end{aligned}$$

繰り返し期待値の法則より

$$\begin{aligned} E(z_i^2 u_i^2) &= E(E(z_i^2 u_i^2 | z_i)) \\ &= E(z_i^2 E(u_i^2 | z_i)) \\ &= E(z_i^2 \text{var}(u_i | z_i)) \\ &= \sigma^2 E(z_i^2) \end{aligned}$$

これを前定理の結果に代入すればよい。□

2.4 弱い IV (p. 202)

定義 9. $E(ZX) \approx 0$ で $E(ZU) = 0$ なら Z は弱い IV という。

注 12. $\beta = E(ZY)/E(ZX)$ より $E(ZX) \approx 0$ だと推定値が不安定になる。また前定理より IV 推定量の漸近分散は $\text{var}(ZU)/E(ZX)^2$ 。したがって $E(ZX) \approx 0$ だと推定の精度が低い。

3 2 段階最小 2 乗法 (2SLS)

3.1 2 段階最小 2 乗法 (2SLS) (p. 205)

(Y, X, Z) を確率ベクトルとする。 Y の X 上への線形モデルは

$$\begin{aligned} Y &= \alpha + \beta X + U \\ E(U) &= 0 \end{aligned}$$

Z を β の推定の IV とする。 X を Z に回帰した回帰予測を \hat{X} とすると、 \hat{X} は Z の線形変換なので $E(ZU) = 0 \implies E(\hat{X}U) = 0$ 。 すなわち \hat{X} も IV。

定義 10. 各説明変数を全ての IV に回帰して回帰予測を求め、それに被説明変数を回帰する手法を **2 段階最小 2 乗法 (2-Stage Least Squares, 2SLS)** という。

注 13. IV 法は 2SLS で実行する。「IV の数>係数の数」でも 2SLS なら全ての IV を使える。

注 14. 本当に 2 段階で実行すると正しい標準誤差が得られない。 実際は (一般化した) MM 法で実行する。

3.2 構造形と誘導形 (pp. 196, 206)

定義 11. 変数間の理論的な関係を表した連立方程式を**構造形**という。

注 15. 説明変数に内生変数がある式は 2SLS で推定する。

定義 12. 内生変数について構造形を解いた式を**誘導形**という。

注 16. 誘導形の説明変数は外生変数 (= IV) のみなので、2SLS の第 1 段階で使う。

4 今日のキーワード

欠落変数バイアス, 外生変数, 内生変数, 内生性バイアス, 操作変数 (IV), 操作変数 (IV) 法, 識別可能, IV 推定量, 弱い IV, 2 段階最小 2 乗法 (2SLS), 構造形, 誘導形

5 次回までの準備

復習 教科書第 8 章, 復習テスト 11

予習 教科書第 9 章