

第5回 1変量時系列モデルの定式化と推定 (7.1.3, 7.2.2–7.2.3)

村澤 康友

2022年10月25日

今日のポイント

1. $\{\Delta^d y_t\}$ が共分散定常なら $\{y_t\}$ を d 次の和分 (単位根) 過程という. $\{\Delta y_t\}$ が WN なら $\{y_t\}$ をランダム・ウォークという. $\{\Delta^d y_t\}$ が $\text{ARMA}(p, q)$ なら $\{y_t\}$ を (p, d, q) 次の自己回帰和分移動平均 (ARIMA) 過程という.
2. AR モデルの係数の OLS 推定量は不偏でないが一致性をもつ.
3. ARMA モデルの尤度関数は予測誤差分解で計算する. 時系列の同時 pdf を尤度とする ML 法を厳密な ML 法, 初期値を所与とした条件つき pdf を尤度とする ML 法を条件つき ML 法という.
4. ARMA モデルの次数は AIC・SBIC・HQC 等のモデル選択基準で選ぶ.

目次

1	ARIMA 過程	1
1.1	差分と和分	1
1.2	和分 (単位根) 過程 (p. 128)	2
1.3	ARIMA 過程 (p. 138)	2
2	AR モデルの OLS 推定	2
2.1	OLS 推定量	2
2.2	有限標本特性	2
2.3	漸近特性	2

3	正規 ARMA モデルの ML 推定	3
3.1	最尤 (ML) 法	3
3.2	予測誤差分解	3
3.3	厳密な ML 法 (p. 137)	4
3.4	条件つき ML 法	4
4	次数選択	4
4.1	仮説検定とモデル選択	4
4.2	Kullback–Leibler 情報量	4
4.3	モデル選択基準 (p. 132)	4
5	今日のキーワード	5
6	次回までの準備	5

1 ARIMA 過程

1.1 差分と和分

$\{x_t\}$ を $t = 1$ から始まる数列とする.

定義 1. $\{x_t\}$ の差分 (階差) は $\{\Delta x_t\}$.

定義 2. $\{x_t\}$ の和分は $t \geq 1$ について

$$S_t := x_1 + \cdots + x_t$$

注 1. $t \geq 1$ について

$$\begin{aligned}\Delta S_t &:= S_t - S_{t-1} \\ &= x_1 + \cdots + x_t - (x_1 + \cdots + x_{t-1}) \\ &= x_t\end{aligned}$$

すなわち和分は差分の逆の演算. 離散空間上の差分と和分の関係は, 連続空間上の微分と積分の関係に相当.

1.2 和分（単位根）過程（p. 128）

$\{y_t\}$ を確率過程とする。

定義 3. $\{\Delta^d y_t\}$ が共分散定常なら $\{y_t\}$ を d 次の和分（単位根）過程という。

注 2. $I(d)$ と書く。 $I(0)$ = 共分散定常。

注 3. $I(d)$ は $I(0)$ に変換して分析する。

定義 4. $\{\Delta y_t\}$ がホワイト・ノイズなら $\{y_t\}$ をランダム・ウォークという。

注 4. $\{w_t\}$ を WN とすると、任意の t について

$$\Delta y_t = w_t$$

AR(1) は、任意の t について

$$\phi(L)(y_t - \mu) = w_t$$

ただし $\phi(L) := 1 - \phi L$. ランダム・ウォークは $\phi = 1$ の AR(1). このとき $\phi(z) := 1 - z = 0$ の根は $z = 1$ (単位根)。

1.3 ARIMA 過程（p. 138）

$\{y_t\}$ を $I(d)$ とする。

定義 5. $\{\Delta^d y_t\}$ が $\text{ARMA}(p, q)$ なら $\{y_t\}$ を (p, d, q) 次の自己回帰和分移動平均 (ARIMA) 過程という。

注 5. $\text{ARIMA}(p, d, q)$ と書く。

2 AR モデルの OLS 推定

2.1 OLS 推定量

時系列 (y_0, \dots, y_T) に平均 0 の AR(1) モデルを仮定する。すなわち $t = 1, \dots, T$ について

$$y_t = \phi y_{t-1} + w_t \\ \{w_t\} \sim \text{WN}(\sigma^2)$$

ただし $|\phi| < 1$. ϕ の OLS 推定量を $\hat{\phi}_T$ とすると

$$\hat{\phi}_T = \frac{\sum_{t=1}^T y_{t-1} y_t}{\sum_{t=1}^T y_{t-1}^2}$$

2.2 有限標本特性

定理 1. 一般に

$$E(\hat{\phi}_T) \neq \phi$$

証明. 式変形すると

$$\begin{aligned} \hat{\phi}_T &= \frac{\sum_{t=1}^T y_{t-1} y_t}{\sum_{t=1}^T y_{t-1}^2} \\ &= \frac{\sum_{t=1}^T y_{t-1} (\phi y_{t-1} + w_t)}{\sum_{t=1}^T y_{t-1}^2} \\ &= \phi + \frac{\sum_{t=1}^T y_{t-1} w_t}{\sum_{t=1}^T y_{t-1}^2} \end{aligned}$$

第 2 項の期待値は

$$\begin{aligned} E\left(\frac{\sum_{t=1}^T y_{t-1} w_t}{\sum_{t=1}^T y_{t-1}^2}\right) &= \sum_{t=1}^T E\left(\frac{y_{t-1} w_t}{\sum_{t=1}^T y_{t-1}^2}\right) \\ &= E\left(\frac{y_0 w_1}{\sum_{t=1}^T y_{t-1}^2}\right) + \dots + E\left(\frac{y_{T-1} w_T}{\sum_{t=1}^T y_{t-1}^2}\right) \\ &= \text{cov}\left(\frac{y_0}{\sum_{t=1}^T y_{t-1}^2}, w_1\right) + \dots \\ &\quad + \text{cov}\left(\frac{y_{T-1}}{\sum_{t=1}^T y_{t-1}^2}, w_T\right) \end{aligned}$$

w_1 は y_1, \dots, y_{T-1} と相関するので第 1 項は一般に 0 でない。同様に他の項も一般に 0 でない。 \square

注 6. 無作為標本でないため OLS 推定量は不偏でない。

2.3 漸近特性

定理 2.

$$\text{plim}_{T \rightarrow \infty} \hat{\phi}_T = \phi$$

証明. 式変形すると

$$\begin{aligned} \hat{\phi}_T &= \phi + \frac{\sum_{t=1}^T y_{t-1} w_t}{\sum_{t=1}^T y_{t-1}^2} \\ &= \phi + \frac{(1/T) \sum_{t=1}^T y_{t-1} w_t}{(1/T) \sum_{t=1}^T y_{t-1}^2} \end{aligned}$$

エルゴード定理より

$$\begin{aligned}\text{plim}_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T y_{t-1} w_t &= E(y_{t-1} w_t) \\ \text{plim}_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T y_{t-1}^2 &= E(y_{t-1}^2)\end{aligned}$$

漸近演算より

$$\begin{aligned}\text{plim}_{T \rightarrow \infty} \hat{\phi}_T &= \phi + \frac{\text{plim}_{T \rightarrow \infty} (1/T) \sum_{t=1}^T y_{t-1} w_t}{\text{plim}_{T \rightarrow \infty} (1/T) \sum_{t=1}^T y_{t-1}^2} \\ &= \phi + \frac{E(y_{t-1} w_t)}{E(y_{t-1}^2)}\end{aligned}$$

$E(y_{t-1} w_t) = \text{cov}(y_{t-1}, w_t) = 0$ より第 2 項は 0.

□

注 7. すなわち OLS 推定量は一致性をもつ. また漸近正規性も証明できる (省略).

3 正規 ARMA モデルの ML 推定

3.1 最尤 (ML) 法

パラメトリックな確率過程を仮定する. 母数を θ とし, 観測する時系列の同時 pmf・pdf を $f(\cdot; \theta)$ とする.

定義 6. ある母数の下で標本の実現値を観測する確率 (密度) を, その母数の**尤度**という.

注 8. (y_1, \dots, y_T) を観測する確率 (密度) は

$$f(y_1, \dots, y_T; \theta)$$

これを θ の「尤もらしさ」と解釈する.

定義 7. 標本の pmf・pdf を母数の尤度を表す関数とみたものを**尤度関数**という.

注 9. $L(\theta; y_1, \dots, y_T)$ と書く ((y_1, \dots, y_T) と θ の位置が pmf・pdf と逆).

注 10. (y_1, \dots, y_T) を観測したときの θ の尤度関数は

$$L(\theta; y_1, \dots, y_T) := f(y_1, \dots, y_T; \theta)$$

定義 8. 尤度関数の対数を**対数尤度関数**という.

注 11. $\ell(\theta; y_1, \dots, y_T)$ と書く.

注 12. (y_1, \dots, y_T) を観測したときの θ の対数尤度関数は

$$\begin{aligned}\ell(\theta; y_1, \dots, y_T) &:= \ln L(\theta; y_1, \dots, y_T) \\ &= \ln f(y_1, \dots, y_T; \theta)\end{aligned}$$

定義 9. (対数) 尤度関数を最大にする解を母数の推定値とする手法を**最尤** (*maximum likelihood, ML*) 法という.

定義 10. ML 法による推定量を **ML 推定量**という.

定理 3. ML 推定量は一般に漸近有効.

証明. 省略 (大学院レベル).

□

3.2 予測誤差分解

時系列 (y_1, \dots, y_T) の同時 pdf を $f(\cdot)$, 条件つき pdf を $f(\cdot|\cdot)$ で表す.

定理 4 (予測誤差分解). 任意の (y_1, \dots, y_T) について

$$\begin{aligned}f(y_1, \dots, y_T) \\ = f(y_T|y_{T-1}, \dots, y_1) \cdots f(y_2|y_1)f(y_1)\end{aligned}$$

証明. 条件つき pdf の定義より, 任意の (y_1, \dots, y_T) について

$$\begin{aligned}f(y_1, \dots, y_T) \\ = \frac{f(y_1, \dots, y_T)}{f(y_1, \dots, y_{T-1})} \frac{f(y_1, \dots, y_{T-1})}{f(y_1, \dots, y_{T-2})} \cdots \\ \frac{f(y_1, y_2)}{f(y_1)} f(y_1) \\ = f(y_T|y_{T-1}, \dots, y_1) f(y_{T-1}|y_{T-2}, \dots, y_1) \cdots \\ f(y_2|y_1) f(y_1)\end{aligned}$$

□

例 1. 時系列 (y_1, \dots, y_T) に平均 0 の正規 AR(1) モデルを仮定する. すなわち $t = 1, \dots, T$ について

$$\begin{aligned}y_t &= \phi y_{t-1} + w_t \\ \{w_t\} &\sim \text{IN}(0, \sigma^2)\end{aligned}$$

ただし $|\phi| < 1$. $\text{var}(y_1) = \sigma^2 / (1 - \phi^2)$ より

$$y_1 \sim N\left(0, \frac{\sigma^2}{1 - \phi^2}\right)$$

また $t = 2, \dots, T$ について

$$y_t | y_{t-1}, \dots, y_1 \sim N(\phi y_{t-1}, \sigma^2)$$

予測誤差分解より尤度関数は

$$\begin{aligned} L(\phi, \sigma^2; y_1, \dots, y_T) &:= f(y_1, \dots, y_T) \\ &= f(y_T | y_{T-1}, \dots, y_1) \cdots f(y_2 | y_1) f(y_1) \\ &= \prod_{t=2}^T \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_t - \phi y_{t-1})^2}{2\sigma^2}\right) \\ &\quad \frac{1}{\sqrt{2\pi\sigma^2/(1-\phi^2)}} \exp\left(-\frac{y_1^2}{2\sigma^2/(1-\phi^2)}\right) \end{aligned}$$

対数尤度関数は

$$\begin{aligned} \ell(\phi, \sigma^2; y_1, \dots, y_T) &:= \ln L(\phi, \sigma^2; y_1, \dots, y_T) \\ &= \sum_{t=2}^T \left\{ -\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^2 - \frac{(y_t - \phi y_{t-1})^2}{2\sigma^2} \right\} \\ &\quad - \frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \frac{\sigma^2}{1-\phi^2} - \frac{y_1^2}{2\sigma^2/(1-\phi^2)} \\ &= -\frac{T}{2} \ln 2\pi - \frac{T}{2} \ln \sigma^2 + \frac{1}{2} \ln(1-\phi^2) \\ &\quad - \frac{(1-\phi^2)y_1^2}{2\sigma^2} - \frac{1}{2\sigma^2} \sum_{t=2}^T (y_t - \phi y_{t-1})^2 \end{aligned}$$

3.3 厳密な ML 法 (p. 137)

定義 11. (y_1, \dots, y_T) の同時 pdf を尤度とする ML 法を**厳密な ML 法**という。

注 13. 漸近有効だが尤度の計算が複雑 (ARMA モデルを状態空間モデルで表現し、カルマン・フィルタで尤度を計算する)。

3.4 条件つき ML 法

定義 12. 初期値 (y_1, \dots, y_p) と (w_{p-q+1}, \dots, w_p) を所与とした (y_{p+1}, \dots, y_T) の条件つき pdf を尤度とする ML 法を**条件つき ML 法**という。

注 14. 初期値の周辺 pdf を省くため漸近有効でないが、推定が簡単になる。AR モデルなら条件つき ML 法 = OLS。

4 次数選択

4.1 仮説検定とモデル選択

予測モデルの次数選択は仮説検定と異なる。

1. 真の次数が無限大なら真のモデルは推定できず仮説検定も無意味。
2. 真の次数が有限でも推定する係数が多いと予測値が不安定になる。

モデル選択基準による次数選択が便利。

4.2 Kullback-Leibler 情報量

確率変数 Y の真の分布を $f_0(\cdot)$ 、予測モデルの下での分布を $f(\cdot)$ とする。

定義 13. $f(\cdot)$ の $f_0(\cdot)$ に対する *Kullback-Leibler 情報量*は

$$I(f(\cdot); f_0(\cdot)) := -E_{f_0} \left(\ln \frac{f(Y)}{f_0(Y)} \right)$$

注 15. $f(\cdot)$ の $f_0(\cdot)$ に対する「距離」を表す。 $f(\cdot) = f_0(\cdot)$ なら「距離」は 0 で最小。ただし真の次数が無限大なら $f_0(\cdot)$ は予測に使えない。式変形すると

$$I(f(\cdot); f_0(\cdot)) = -E_{f_0}(\ln f(Y)) + E_{f_0}(\ln f_0(Y))$$

第 1 項を最小化、すなわち $E_{f_0}(\ln f(Y))$ を最大化する $f(\cdot)$ が最適な予測モデル。 $E_{f_0}(\ln f(Y))$ は未知なので推定が必要。

4.3 モデル選択基準 (p. 132)

定常過程 $\{Y_t\}$ の 1 期先予測モデルを $f(\cdot; \theta)$ とする。 $E(\ln f(Y_t; \theta))$ を最大化する θ を θ^* とする。 $E(\ln f(Y_t; \theta^*))$ の推定は 2 つの推定を含む。

1. θ^* の推定
2. θ^* を所与とした $E(\ln f(Y_t; \theta^*))$ の推定

θ^* が既知ならエルゴード定理より

$$\text{plim}_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T \ln f(Y_t; \theta^*) = E(\ln f(Y_t; \theta^*))$$

θ^* の ML 推定量を $\hat{\theta}_T$ とする。左辺の θ^* を $\hat{\theta}_T$ で置き換えると右辺の推定量として偏りが生じるので修正が必要。未知係数の数を k とする。

補題 1. 任意の θ と (y_1, \dots, y_T) について

$$\sum_{t=1}^T \ln f(y_t; \theta) = \ell(\theta; y_1, \dots, y_T)$$

証明. 予測誤差分解より

$$f(y_1, \dots, y_T; \theta) = \prod_{t=1}^T f(y_t; \theta)$$

したがって

$$\begin{aligned} \ell(\theta; y_1, \dots, y_T) &:= \ln f(y_1, \dots, y_T; \theta) \\ &= \sum_{t=1}^T \ln f(y_t; \theta) \end{aligned}$$

□

定義 14. 赤池の情報量基準 (*Akaike's information criterion, AIC*) は

$$\text{AIC} := -2\ell(\hat{\theta}_T; y_1, \dots, y_T) + 2k$$

注 16. AIC が最小のモデルを選択する. 第 2 項は偏りの修正項であり, モデルの大きさに対するペナルティーと解釈できる.

定義 15. 真のモデルを選ぶ確率が $T \rightarrow \infty$ で 1 に収束する性質をモデル選択基準の**一貫性**という.

注 17. AIC は一貫性をもたない (過剰定式化の傾向がある).

定義 16. Schwarz のベイズ情報量基準 (*Schwarz's Bayesian information criterion, SBIC*) は

$$\text{SBIC} := -2\ell(\hat{\theta}_T; y_1, \dots, y_T) + k \ln T$$

注 18. θ^* をベイズ法で推定した場合の周辺尤度 $E(\ell(\theta^*; y_1, \dots, y_T))$ のラプラス近似から得られる.

注 19. SBIC は一貫性をもつ. $\ln T > 2$ ならモデルの大きさに対するペナルティーが AIC より大きく, AIC より小さいモデルを選択する.

定義 17. Hannan-Quinn の基準 (*Hannan-Quinn criterion, HQC*) は

$$\text{HQC} := -2\ell(\hat{\theta}_T; y_1, \dots, y_T) + 2k \ln \ln T$$

注 20. HQC も一貫性をもつ. モデルの大きさに対するペナルティーは AIC と SBIC の中間.

5 今日のキーワード

差分 (階差), 和分, 和分 (単位根) 過程, ランダム・ウォーク, 自己回帰和分移動平均 (ARIMA) 過程, 尤度, 尤度関数, 対数尤度関数, 最尤 (ML) 法, ML 推定量, 予測誤差分解, 厳密な ML 法, 条件つき ML 法, Kullback-Leibler 情報量, 赤池の情報量基準 (AIC), 一貫性, Schwarz のベイズ情報量基準 (SBIC), Hannan-Quinn の基準 (HQC)

6 次回までの準備

提出 宿題 5

復習 教科書第 7 章 1.3, 2.2–2.3 節, 復習テスト 5

予習 教科書第 7 章 4.1 節