第 2 回　1 変量データの整理（2）

村澤 康友

2025 年 9 月 30 日

今日のポイント

1. 変量の尺度（名義／順序／間隔／比）により，適切なデータ整理の方法は異なる．
2. 度数分布（表／ヒストグラム）はデータ整理の基本．
3. 記述統計量（位置／散らばり）でデータの特徴をみる．

目次

1　変量の尺度（p. 27）

変量の尺度により，適切なデータ整理の方法は異なる．

定義 1. 順序がない分類を**名義尺度**という．

注 1. 「最大値」「最小値」「平均」は無意味．

例 1. 婚姻状態（未婚・既婚・離別・死別）．

定義 2. 順序がある分類を**順序尺度**という．

注 2. 「平均」は無意味．

例 2. 最終学歴（中卒・高卒・大卒）．

定義 3. 間隔のみが意味をもつ量を**間隔尺度**という．

例 3. 摂氏・華氏，時刻．

定義 4. 比率が意味をもつ量を**比尺度**という．

注 3. 一般に正の値しかとらない．

例 4. 身長，体重，時間，絶対（熱力学）温度．

2　度数分布（p. 18）

2.1　度数（p. 18）

まず最初に観測値の範囲をいくつかの**階級**に分割する．

定義 5. ある階級に含まれる観測値の数を，その階級の**度数**という．

定義 6. （度数）／（観測値の総数）を**相対度数**という．

例 5. 某大学 1 年生の入試成績（英語）の度数分布（表 1）．

定義 7. 横軸に値をとり，各階級の（相対）度数を柱の面積で表したグラフを**ヒストグラム（柱状グラフ）**という．

注 4. 柱の高さで表す棒グラフとは異なる．階級分

表 1　某大学 1 年生の入試成績（英語）の度数分布

階級	度数	相対度数
200〜250	2	.00
250〜300	11	.03
300〜350	15	.04
350〜400	30	.07
400〜450	63	.15
450〜500	95	.22
500〜550	92	.22
550〜600	67	.16
600〜650	33	.08
650〜700	19	.04
計	427	1.00

けしない離散変量は棒グラフでよい．

注 5. ヒストグラムの印象は階級の取り方により異なる．粗すぎても細かすぎてもダメ．

例 6. 某大学 1 年生の入試成績（英語）のヒストグラム（図 1）.

2.2　累積度数（p. 19）

定義 8. ある階級以下の度数の和を，その階級までの**累積度数**という．

注 6. 名義尺度なら無意味.

定義 9. （累積度数）／（観測値の総数）を**累積相対度数**という．

例 7. 某大学 1 年生の入試成績（英語）の累積度数分布（表 2）.

定義 10. 累積（相対）度数の折れ線グラフを**累積（相対）度数グラフ**という．

注 7. 階級が細かいほど滑らかなグラフとなる．

例 8. 某大学 1 年生の入試成績（英語）の累積度数グラフ（図 2）.

定義 11. 横軸に累積相対度数，縦軸に（その階級以下の観測値の総和）／（全観測値の総和）をとった折れ線グラフを**ローレンツ曲線**という．

注 8. 全観測値が等しければ 45 度線に一致．下に行くほど「不平等」な分布.

注 9. データの大きさに関わらず，累積相対度数分布が同じなら，ローレンツ曲線は同じになる．

例 9. 某大学 1 年生の入試成績（英語）のローレンツ曲線（図 3）.

練習 1. 以下の 3 つのデータについて，それぞれローレンツ曲線を描きなさい．

1. $(2, 2, 2, 2, 2)$
2. $(0, 0, 0, 0, 10)$
3. $(0, 1, 2, 3, 4)$

3　記述統計量（p. 28）

3.1　総和記号

定義 12.

$$\sum_{i=1}^{n} x_i := x_1 + \cdots + x_n$$

練習 2. 以下の公式を示しなさい．

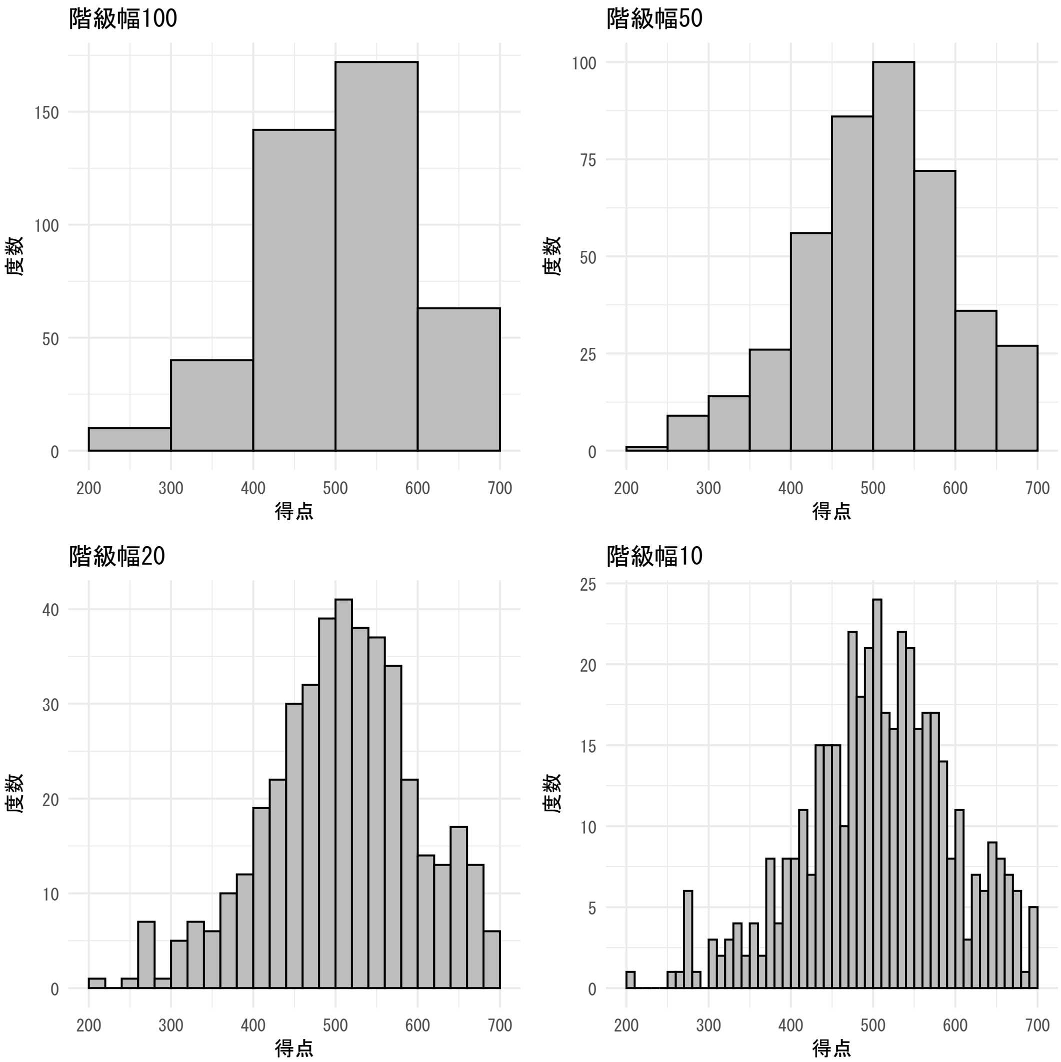

図 1　某大学 1 年生の入試成績（英語）のヒストグラム

1. $\sum_{i=1}^{n} 1 = n$
2. $\sum_{i=1}^{n} a x_i = a \sum_{i=1}^{n} x_i$
3. $\sum_{i=1}^{n} (x_i + y_i) = \sum_{i=1}^{n} x_i + \sum_{i=1}^{n} y_i$

3.2　位置（p. 28）

定義 13. （観測値の総和）／（観測値の総数）を**（算術）平均**という.

注 10. 質的変量なら無意味.

注 11. 観測値を $(x_1, \ldots, x_n)$ とすると（とりあえず母集団と標本は区別しない）

$$\mu := \frac{x_1 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

定義 14. 観測値を小さい方から順に並べたときの中央の値を**中位数**という.

注 12. データの総数が偶数で中央の値が存在しない場合は両隣の間をとる.

注 13. 順序尺度でも意味をもつ.

注 14. 対称な分布なら平均＝中位数.

定義 15. 観測値を小さい方から順に並べたときの

表 2　某大学 1 年生の入試成績（英語）の累積度数分布

階級	累積度数	累積相対度数
200～250	2	.00
250～300	13	.03
300～350	28	.07
350～400	58	.14
400～450	121	.28
450～500	216	.51
500～550	308	.72
550～600	375	.88
600～650	408	.96
650～700	427	1.00

αn 番目の値を α **分位数（点）**という．

注 15. αn 番目の値が存在しない場合は両隣の間をとる．

注 16. 中位数は 0.5 分位数．

定義 16. $i/4$ 分位数を**第** i **四分位数**という．

定義 17. $i/5$ 分位数を**第** i **五分位数**という．

定義 18. $i/10$ 分位数を**第** i **十分位数**という．

定義 19. $i/100$ 分位数を**第** i **百分位数（パーセント点）**という．

定義 20. 度数が最大となる値を**最頻値**という．

注 17. 階級の取り方に依存する．

注 18. 名義尺度でも意味をもつ．

注 19. 対称で単峰な分布なら平均＝中位数＝最頻値．

3.3　散らばり（p. 35）

定義 21. （最大値）−（最小値）を**範囲（レンジ）**という．

定義 22. （第 3 四分位数）−（第 1 四分位数）を**四分位範囲**（*interquartile range, IQR*）という．

定義 23. IQR/2 を**四分位偏差**という．

定義 24. 平均からの偏差の 2 乗の平均を**分散**という．

注 20. 式で表すと

$$\begin{aligned}\sigma^2 &:= \frac{(x_1-\mu)^2+\cdots+(x_n-\mu)^2}{n}\\ &= \frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)^2\end{aligned}$$

定義 25. 分散の平方根を**標準偏差**という．

定義 26. （標準偏差）／（平均）を**変動係数**という．

注 21. 変動係数は測定単位の影響を受けない．

注 22. 平均が正でないと（比尺度でないと）無意味．

定義 27. （ローレンツ曲線と 45 度線の間の面積）／（45 度線の下の面積）を**ジニ係数**という．

注 23. 45 度線の下の面積は 1/2.

注 24. 不平等度（格差）を表す．

4　今日のキーワード

名義尺度，順序尺度，間隔尺度，比尺度，度数，相対度数，ヒストグラム（柱状グラフ），累積度数，累積相対度数，累積（相対）度数グラフ，ローレンツ曲線，（算術）平均，中位数，分位数（点），四分位数，五分位数，十分位数，百分位数（パーセント

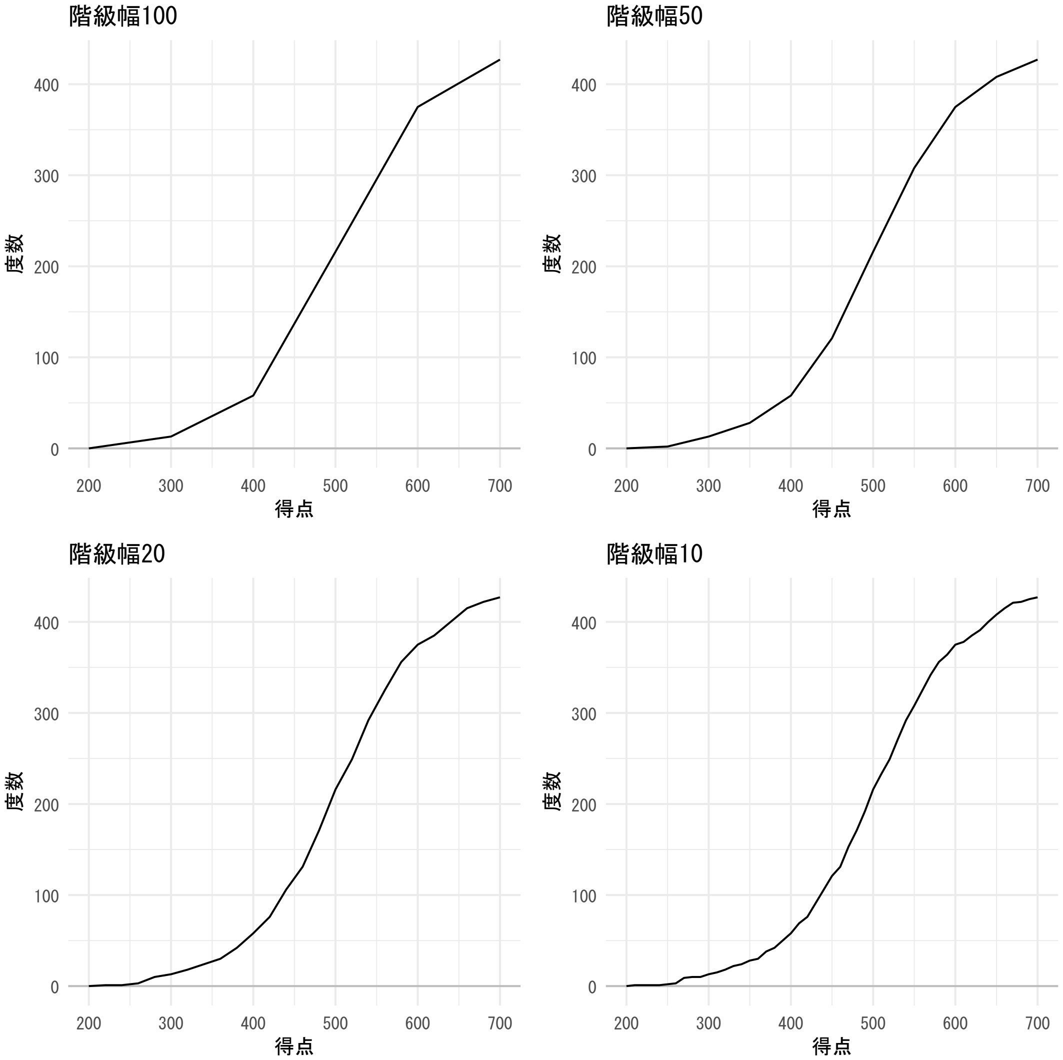

図 2　某大学 1 年生の入試成績（英語）の累積度数グラフ

点），最頻値，範囲（レンジ），四分位範囲（IQR），
四分位偏差，分散，標準偏差，変動係数，ジニ係数

5　次回までの準備

復習　教科書第 2 章，復習テスト 2

予習　教科書第 3 章

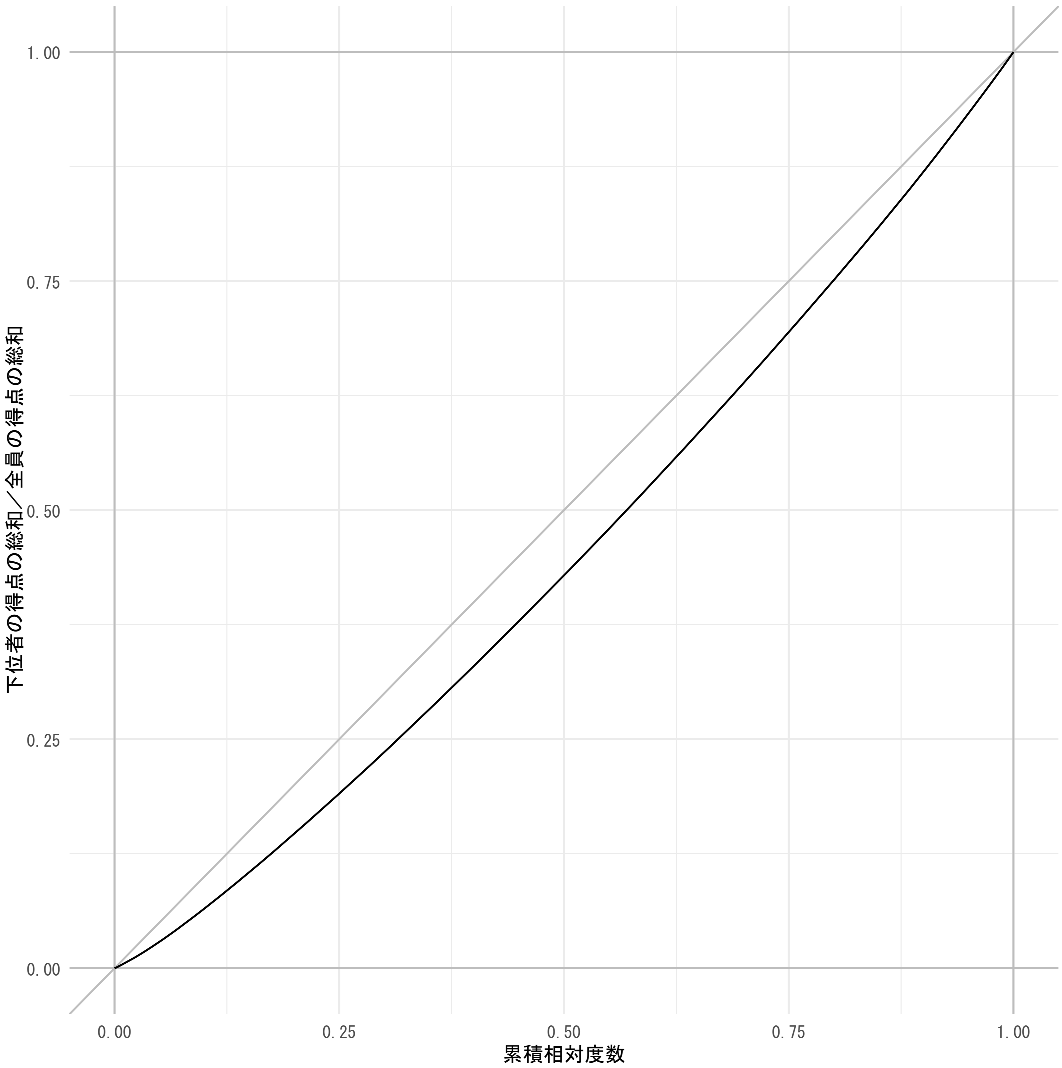

図３　某大学１年生の入試成績（英語）のローレンツ曲線